



# Radiogenomics Framework — Prédiction du statut

## MGMT

### Radiomics + Machine Learning classique (sans deep learning)

Dataset : RSNA-MICCAI Brain Tumor Radiogenomic Classification (BraTS 2021, Tâche 2) · IRM multimodales *FLAIR, T1w, T1wCE, T2w* · Cible : méthylation du promoteur MGMT (classification binaire 0/1)

### CHAÎNE DE TRAITEMENT (END-TO-END PIPELINE)



#### 1. OBJECTIF CLINIQUE

MGMT est une enzyme de réparation de l'ADN. Son promoteur méthylé (silencé) rend le glioblastome (GBM) **plus sensible au témozolomide** et améliore le pronostic. Le déterminer sans biopsie invasive, à partir de l'IRM seule, est l'enjeu de la **radiogénomique** : relier des biomarqueurs d'imagerie (*radiomics*) au statut moléculaire.

#### 3. EXTRACTION RADIOMICS

Trois familles de descripteurs, extraites pour **chacune des 4 modalités** ( $\approx 19 \times 4 = 76$  variables) :

- ▶ **Intensité (first-order)** : moyenne, écart-type, skewness, kurtosis, énergie, entropie, quartiles.
- ▶ **Texture (GLCM)** : contraste, corrélation, homogénéité, dissimilarité, énergie.
- ▶ **Forme** : aire, solidité, excentricité, périmètre, compacité.

#### 5. ASSOCIATION RADIOGÉNOMIQUE

- ▶ Test **Mann-Whitney U** (non-paramétrique) par variable : MGMT- vs MGMT+.
- ▶ Taille d'effet (*rank-biserial*) + correction multi-tests **FDR Benjamini-Hochberg** ( $q < 0,05$ ).
- ▶ Visualisation : *volcano plot* + box-plots des variables discriminantes.

#### 7. ÉVALUATION

**Validation croisée stratifiée 5-fold** comme protocole principal, métriques **ROC-AUC** (référence), accuracy et F1 ; courbes ROC par fold, matrice de confusion, *classification report*, et interprétation biologique des variables les plus discriminantes (entropie, texture GLCM, forme).

#### 2. PRÉTRAITEMENT & ROI

- ▶ Lecture DICOM `pydicom`, coupes centrales (les plus informatives).
- ▶ Normalisation **z-score**, clip à  $\pm 3\sigma$ , redimensionnement 128×128.
- ▶ **Pseudo-ROI** (approximation, pas de vraie segmentation) : recadrage central 60 % + seuillage d'intensité (*hyperintensité FLAIR/T2/T1wCE*).

#### 4. SÉLECTION DE VARIABLES

Stratégie multi-méthodes puis **consensus** (variable retenue si  $\geq 2$  méthodes la classent en tête) :

- ▶ Filtre de **corrélation** ( $r > 0,90$ ) pour la redondance.
- ▶ *ANOVA F-test*, *Mutual Information*, *LASSO* (L1), importance *Random Forest*.

#### 6. FUSION MULTIMODALE & MODÈLES

- ▶ Comparaison : chaque modalité seule vs **les 4 fusionnées** (hypothèse : la fusion domine).
- ▶ Modèles : **Régression Logistique**, **Random Forest**, + *Dummy* (baseline).
- ▶ Avant / après sélection de variables pour en mesurer le gain.

### LIMITES & POINTS DE VIGILANCE

- ▶ **N = 50 patients** seulement (sous-échantillon pour la rapidité) : sous-puissance statistique — passer aux ~585 patients pour conclure.
- ▶ **Pseudo-ROI** heuristique (pas de masque de segmentation BraTS / nnU-Net) : variables moins spécifiques à la lésion.
- ▶ Matrice de confusion & rapport calculés sur **toutes les données** (« for display only ») → optimistes ; citer uniquement **l'AUC en 5-fold CV**.
- ▶ La littérature montre que la prédiction MGMT par IRM seule est **peu reproductible** en validation externe (souvent  $\approx$  hasard).

# Lexique — Termes techniques & biologiques

Chaque terme employé dans la fiche, expliqué en mots simples (**niveau débutant**) — avec le terme anglais entre parenthèses.

## Biologie & médecine

**ADN** (*DNA*) — la molécule qui contient le « mode d'emploi » de la cellule, écrit avec 4 lettres chimiques (A, T, G, C).

**Gène** (*gene*) — un morceau d'ADN qui sert de recette pour fabriquer une protéine précise.

**Promoteur** (*promoter*) — l'« interrupteur » situé au début d'un gène : il décide s'il est allumé ou éteint.

**Méthylation** (*methylation*) — un petit « autocollant » chimique posé sur l'ADN qui vient **éteindre** le gène concerné.

**MGMT** — un gène de réparation de l'ADN. S'il est méthylé (éteint), la tumeur répond **mieux** à la chimiothérapie.

**Glioblastome** (*GBM*) — la tumeur du cerveau la plus fréquente et la plus agressive chez l'adulte.

**Témolozolomide** — le médicament de chimiothérapie standard utilisé contre le glioblastome.

**Biomarqueur** (*biomarker*) — un signal mesurable qui renseigne sur une maladie (ici : le statut MGMT).

**Radiogénomique** (*radiogenomics*) — relier ce qu'on voit sur une image médicale au profil génétique de la tumeur.

## Imagerie & données

**IRM** (*MRI*) — machine qui photographie l'intérieur du corps avec des aimants, sans rayons X.

**Modalité / séquence** — un « réglage » de l'IRM. *FLAIR, T1w, T1wCE, T2w* font ressortir des tissus différents.

**DICOM** — le format de fichier standard des images médicales (comme le .jpg, mais pour l'hôpital).

**pydicom** — une bibliothèque Python (boîte à outils de code) pour lire les fichiers DICOM.

**ROI** (*Region of Interest*) — la zone précise de l'image qu'on veut analyser (ici, la tumeur).

**Segmentation** — entourer exactement la tumeur sur l'image, pixel par pixel.

**Pseudo-ROI** — une zone **approximative** (pas une vraie segmentation) : plus rapide, mais moins précise.

**Normalisation z-score** — remettre toutes les images à la même échelle pour pouvoir les comparer.

## Radiomics & variables

**Radiomics** — transformer une image en une liste de chiffres mesurables (luminosité, texture, forme).

**Variable** (*feature*) — une caractéristique chiffrée extraite de l'image (une colonne de données).

**Intensité** (*first-order*) — statistiques simples sur la luminosité des pixels (moyenne, écart-type...).

**Texture** (*GLCM*) — mesure si les pixels voisins se ressemblent : décrit la « texture » de la zone.

**Forme** (*shape*) — mesures géométriques de la zone : aire, périmètre, rondeur...

**Sélection de variables** (*feature selection*) — ne garder que les caractéristiques les plus utiles.

**Corrélation** — deux variables qui varient ensemble ; on en retire une si elles font double emploi.

**ANOVA / Mutual Information** — deux méthodes pour repérer les variables qui distinguent les groupes.

**LASSO** — une méthode qui met automatiquement à zéro les variables inutiles.

## Machine Learning & évaluation

**Machine Learning** — apprendre à un programme à prédire à partir d'exemples chiffrés.

**Deep Learning** (*CNN*) — ML avec de gros réseaux de neurones. **Non utilisé** ici.

**Régression Logistique** — modèle simple qui prédit une probabilité entre 0 et 1 (oui/non).

**Random Forest** — combine plein de petits « arbres de décision » qui votent la réponse.

**Dummy** (*baseline*) — un faux modèle qui devine bêtement, pour vérifier qu'on fait mieux que lui.

**Mann-Whitney U** — test qui compare deux groupes sans supposer une courbe en cloche (*non-paramétrique*).

**FDR / Benjamini-Hochberg** — correction qui évite les fausses découvertes quand on fait beaucoup de tests.

**p-value / q-value** — probabilité que le résultat soit dû au hasard ; plus c'est petit, plus c'est fiable.

**Validation croisée 5-fold** (*cross-validation*) — tester le modèle sur 5 découpages différents pour un résultat honnête.

**ROC-AUC** — note de 0,5 (hasard) à 1 (parfait) qui mesure la qualité d'un classifieur.

**Matrice de confusion** — tableau qui montre les bonnes et les mauvaises prédictions.

**Volcano plot** — graphique qui montre d'un coup quelles variables sont les plus significatives.